

Министерство образования и науки Российской Федерации
Московский физико-технический институт (государственный университет)

Физтех-школа радиотехники и компьютерных технологий
Кафедра микропроцессорных технологий в интеллектуальных системах управления

Выпускная квалификационная работа бакалавра

Удаление примитивных типов из высокоуровневого языка программирования для улучшения качества семантического анализа

Автор:

Студентка группы Б01-109а
Ермолаева Варвара Дмитриевна

Научный руководитель:

Солдатов Антон Анатольевич

Научный консультант:

Солдатов Антон Анатольевич



Москва 2025

Аннотация

Удаление примитивных типов из высокоуровневого языка
программирования для улучшения качества семантического анализа
Ермолаева Варвара Дмитриевна

бебебебебе ляляляляля

Abstract

бебебебе ляляля

Содержание

1	Введение	5
1.1	Типовая система	5
1.2	Статическая и динамическая типизации	6
1.3	Примитивные типы	7
1.3.1	Роль в конструировании типов	7
1.3.2	Основные характеристики	7
1.3.3	Примеры в высокоуровневых языках	7
1.4	Роль примитивных типов в управляемых средах исполнения	8
1.4.1	Основные функции и компоненты среды исполнения	8
1.4.2	Примитивные типы в управляемых средах исполнения	9
1.5	Несогласованность примитивных типов в управляемых языках программирования	10
2	Постановка задачи	13
2.1	Контекст	13
2.2	Задачи исследования	13
2.3	Требования к решению	14
2.3.1	Функциональные требования	14
2.3.2	Нефункциональные требования	15
2.4	Ожидаемые результаты	16
3	Обзор существующих решений	17
3.1	Явное разделение с автоматическим преобразованием	17
3.2	Единая иерархия типов с значимыми типами	18
3.3	Примитивы как оптимизация компилятора	19
3.4	Полное удаление примитивных типов	20
4	Исследование и построение решения задачи	22
4.1	Архитектурное решение	22
4.2	Обоснование выбора стратегии	22
4.3	Описание решения	23
4.4	Изменения в семантике языка	23
4.4.1	Эквивалентные сценарии	23
4.4.2	Новые допустимые конструкции	24
4.5	План реализации	24
5	Описание практической части	25
5.1	Арифметические операции	25
5.2	Преобразования типов	25
5.2.1	Основные функции	25
5.3	Свёртка констант	27
5.3.1	Основной алгоритм	27
5.3.2	Поддерживаемые типы и операции	28
5.3.3	Детали реализации	28
5.3.4	Основные функции	29
5.4	Оптимизация	31
5.4.1	Класс UnboxVisitor	31
5.4.2	Обрабатываемые узлы AST	31
5.4.3	Механизм работы Visitor'ов	31

5.4.4	Пример обработки CallExpression	32
5.4.5	Логика преобразования типов	32
5.4.6	Пример преобразования	33
6	Заключение	34

1 Введение

Типовая система языка программирования служит фундаментом для формального определения его спецификации, обеспечивает статический анализ программ, поддержку оптимизаций кода и способствует улучшению его структурированности и читаемости. Высокоуровневые языки программирования (Java, C#, Kotlin) предоставляют разработчику мощные абстракции и безопасность кода посредством автоматического управления памятью и объектно-ориентированных парадигм. Многие из этих языков сохранили в себе исторически сложившееся разделение типов на "примитивные" типы и "объектные" или "ссылочные", призванное потенциально улучшить производительность в некоторых случаях. Тем не менее, в то же время оно приводит к несогласованности в системе типов и усложняет достижение полностью единообразной и интуитивной модели программирования. Примитивные типы часто лишены полезных свойств объектов, таких как наследование, полиморфизм, вызов методов без явного упаковывания/распаковывания и использование в качестве аргумента для шаблонных типов.

В данной работе будут теоретически рассмотрены последствия устранения явной разницы между примитивными и объектными типами из высокоуровневого управляемого языка программирования и описаны этапы и результаты реализации.

1.1 Типовая система

Типовая система — следуя определению Пирса[1], это формальная синтаксическая и семантическая структура, сопоставляющая типы и программные конструкции (выражения, переменные, функции) для обеспечения чётко определённого вычислительного поведения. Её основные теоретические и практические назначения:

1) Корректность поведения программы

С введением типовой системы становится возможной статическая верификация соблюдения ограничений типов, не допускающая к выполнению неверно типизированные программы. Данный механизм гарантирует:

- *Безопасность выполнения* — предотвращение неопределённого поведения за счёт блокировки запрещённых операций (например, некорректные обращения к памяти в управляемых средах типа JVM (Java Virtual Machine)/CLR (Common Language Runtime))
- *Теоретическую обоснованность* — соответствие двум фундаментальным принципам типобезопасности по Райту-Феллейзену [2]:
 1. **Прогресс:** корректно типизированная программа не может застрять в промежуточном состоянии
 2. **Сохранение:** типы остаются согласованными на всех этапах вычисления

2) Уровень абстракции кода

Типовая система обеспечивает инкапсуляцию доменных инвариантов с помощью абстракций типов (абстрактные типы данных и интерфейсы) и позволяет формально специфицировать границы модулей.

3) Возможность оптимизаций

Наличие статической типизации позволяет применять оптимизации на этапе компиляции (например, специализация шаблонных типов и статическое разрешение методов) и минимизировать время исполнения в управляемых средах за счёт уменьшения количества динамических проверок типов.

1.2 Статическая и динамическая типизации

1. Статическая типизация (Java, C#, Kotlin):

- Валидность типа доказывается на этапе компиляции с помощью формальных суждений о принадлежности выражения к типу в данном контексте ($\Gamma \vdash e : \tau$)
- Гарантирует типобезопасность по Райту-Феллейзену
- Критично для управляемых языков программирования из-за возможности проверок безопасности памяти (например, верификатор байт-кода JVM) и эффективности Just-In-Time компиляции за счёт встраивания методов, ориентированных на конкретный тип

2. Динамическая типизация (Python, JavaScript):

- Типы функций и выражений определяются во время исполнения
- Нет формальной гарантии типобезопасности, но есть возможность менять поведение объектов, модулей и классов во время исполнения

Современные управляемые языки высокого уровня (Java, C#) преимущественно основаны на статической типизации, расширенной возможностями динамического анализа во время выполнения. Данный компромиссный подход позволяет сочетать строгость формальной верификации с практической гибкостью разработки, но противоречие между статическими гарантиями и динамической адаптируемостью продолжает оставаться предметом активных исследований.

Исторически и архитектурно, многие языки разделяют типы на две категории: **Примитивные типы** (далее – примитивные типы или примитивы) Представляют собой базовые значения (например, целые числа, числа с плавающей точкой, булевы значения, символы). **Ссылочные типы** (далее - ссылочные типы, объектные типы) Представляют собой экземпляры классов, которые хранятся в куче (heap) и управляются сборщиком мусора. Они наследуются от базового класса и обладают методами, полями и другими объектно-ориентированными свойствами.

1.3 Примитивные типы

Примитивные типы являются наиболее фундаментальным типом данных в языках программирования. В отличие от объектных типов, они:

- **Не ссылают на память**, а непосредственно являются значениями. У них отсутствуют:
 - заголовок объекта (object header)
 - таблица виртуальных методов (vtable)
 - ссылочная идентичность (identity)
- Имеют **фиксированную семантику**, определяющуюся стандартами языка (например, Java JLS §4.2 [3], C# ECMA-334 §8.3 [4])
- **Не могут быть подтипами** или наследоваться и являются атомарными (базовыми) элементами в иерархии типов

1.3.1 Роль в конструировании типов

В теории типов примитивы являются простейшими случаями конструирования типа и не разлагаются на более простые типы. Конструирование сложных типов происходит на основе:

- **Произведения** (кортежи, записи) – (Int, Bool)
- **Суммы** (типы-суммы, перечисления) – `data Maybe a = Nothing | Just a`
- **Функции** – `Int → Bool`
- **Рекурсивные типы** – `data List a = Nil | Cons a (List a)`

1.3.2 Основные характеристики

- **Представление в памяти**

Аллокация на стеке (за исключением глобальных переменных)
- **Производительность на уровне процессора**
 1. Арифметические операции с примитивами компилируются непосредственно в нативные инструкции:

```
1      ; x86 assembly for 'a + b'
2      mov eax, [a]
3      add eax, [b]
```
 2. **Локализация в кэше**

Линейная модель доступа к памяти (критично для больших вычислений)

1.3.3 Примеры в высокоуровневых языках

Тип	Java	C#
Целые числа	int, long	int, long
Числа с плавающей	float, double	float, double
Булевы значения	boolean	bool
Символ	char	char

1.4 Роль примитивных типов в управляемых средах исполнения

Управляемая среда исполнения (Managed Execution Environment) — это программный компонент или слой, который обеспечивает выполнение программного кода в контролируемой, безопасной и абстрагированной от низкоуровневых деталей среде. Она действует как посредник между скомпилированным (или интерпретируемым) кодом приложения и базовой операционной системой или аппаратным обеспечением.

1.4.1 Основные функции и компоненты среды исполнения

Виртуальная Машина (ВМ) / Интерпретатор: Ядро среды исполнения, которое выполняет промежуточный код (байт-код или Common Intermediate Language – CIL). Примеры включают Java Virtual Machine и Common Language Runtime для .NET. ВМ изолирует исполняемый код от конкретной аппаратной архитектуры и операционной системы.

JIT-компиляция (Just-In-Time Compilation): Для повышения производительности многие ВМ используют JIT-компиляторы. Они динамически переводят промежуточный код в машинный код непосредственно перед его выполнением. JIT-компиляторы могут применять оптимизации на основе профилирования времени выполнения, что часто позволяет достичь производительности, сопоставимой с нативно скомпилированным кодом.

Загрузчики Классов/Сборок: Эти компоненты отвечают за динамическую загрузку программных модулей (классов, библиотек, сборок) по мере их необходимости во время выполнения программы. Они также управляют разрешением зависимостей и проверкой целостности загружаемых компонентов.

Система Управления Потоками: Среда исполнения предоставляет интерфейс и механизмы для создания, управления и синхронизации потоков выполнения, обеспечивая эффективную поддержку параллельных вычислений.

Система Безопасности: Высокоуровневые языки программирования часто включают встроенные модели безопасности (например, песочницы), которые контролируют доступ исполняемого кода к системным ресурсам, таким как файловая система, сеть или другие процессы, что особенно важно для кода, загружаемого из недоверенных источников.

Встроенные Сервисы: К ним относятся механизмы обработки исключений, рефлексия (возможность интроспекции и модификации структуры кода во время выполнения), сериализация, а также поддержка взаимодействия с нативным кодом (Native Interface).

1.4.2 Примитивные типы в управляемых средах исполнения

Примитивные типы данных в контексте управляемых сред исполнения (таких как .NET CLR и Java VM) обладают характеристиками и принципами работы, отличающимися от неуправляемых сред, например, реализованных на языках C/C++.

Абстракция и безопасность

Управляемые среды исполнения предоставляют уровень абстракции, скрывающий детали низкоуровневого представления примитивных типов данных в памяти. Это обеспечивает платформонезависимость и переносимость программного обеспечения. Кроме того, такие среды реализуют строгую проверку типов как на этапе компиляции, так и во время исполнения, что служит профилактикой ошибочного использования типов данных и возникновения уязвимостей, связанных с выделением памяти и выходом за границы допустимых областей.

Гарантированная инициализация

В отличие от неуправляемых сред, где переменные могут содержать неинициализированные значения, управляемые среды гарантируют автоматическую инициализацию переменных примитивных типов значениями по умолчанию. Это исключает возможность непредсказуемого поведения, связанного с использованием мусорных значений памяти.

Сборка мусора

В управляемых средах примитивные типы данных, как правило, не подлежат сборке мусора напрямую. Обычно они размещаются в стеке либо, если выступают в роли компонентов объектов, внутри кучи. Освобождение памяти, занятой объектами (соответственно, и их полями-примитивами), происходит посредством встроенного механизма сборки мусора, что снимает с разработчика необходимость вручную управлять памятью.

Стандартное поведение

Управляемые среды исполнения гарантируют предсказуемое и стандартизированное поведение всех операций с примитивными типами данных, в том числе арифметических. Данная особенность повышает надежность и упрощает переносимость программ между различными аппаратными и программными платформами.

Механизм упаковки и распаковки

Управляемые среды поддерживают механизм упаковки (*от англ. boxing, далее - боксинг, упаковка*) и распаковки (*от англ. unboxing, далее - распаковка, анбоксинг*), позволяющий преобразовывать значения примитивных типов в объекты и обратно. Это особенно актуально при взаимодействии с универсальными коллекциями и другими структурами, требующими объектного представления данных. Например, в среде C# значение типа `int` может быть преобразовано в объект (*boxing*) и обратно (*unboxing*).

Примеры реализации

- **.NET (например, на C#):** Примитивные типы (такие как `System.Int32`) реализованы в виде структур и обеспечивают предсказуемое поведение за счёт встроенных механизмов среды.
- **Java:** Примитивные типы (`int`, `boolean`, `char`) имеют фиксированные размеры и поведение. Для поддержки упаковки и распаковки используются соответствующие классы-обёртки (`Integer`, `Boolean`, `Character`).

1.5 Несогласованность примитивных типов в управляемых языках программирования

В большинстве управляемых языков программирования (таких как Java, C#, Python) существует проблема несогласованности обработки примитивных типов данных и объектных типов в рамках единой системы типов. Эта асимметрия оказывает существенное влияние на архитектуру языка, его производительность и способность к применению принципов объектно-ориентированного программирования.

Отсутствие единообразия в системе типов

Одной из ключевых проблем является отсутствие унифицированного представления примитивных и объектных типов в системе типов управляемого языка. Это бинарное разделение приводит к концептуальной и синтаксической асимметрии. Например, примитивные типы не могут быть `null` (без дополнительных обёрток), не поддерживают полиморфизм и не могут использоваться там, где требуется экземпляр класса `Object` (например, в универсальных коллекциях) без явного или неявного преобразования.

Ограничения в Объектно-Ориентированных Возможностях

Несогласованность примитивных типов создает существенные ограничения для применения объектно-ориентированных парадигм: инкапсуляция, наследование и полиморфизм.

- **Отсутствие наследования и полиморфизма:** Примитивные типы не могут наследоваться, и к ним не применимы механизмы полиморфизма через интерфейсы или абстрактные классы. Это означает, что функции, ожидающие экземпляр

базового класса или интерфейса, не могут напрямую работать с примитивными значениями.

- **Проблемы с коллекциями и шаблонных типами:** Для включения примитивных значений в объектные коллекции (например, `ArrayList<Object>` в Java или `List<object>` в C#) требуется механизм автоматической или явной упаковки (boxing) в соответствующие объектные обертки (например, `Integer` для `int`, `Double` для `double`). Это не только нарушает прозрачность и чистоту кода, но и может приводить к неожиданным побочным эффектам или ошибкам типизации, если разработчик не учитывает процесс упаковки/распаковки.
- **Нарушение унифицированного доступа:** Объектно-ориентированный дизайн стремится к унифицированному доступу к данным и поведению через методы. Примитивные типы не обладают методами, так что разработчик должен использовать процедурные подходы или статические вспомогательные классы для выполнения операций над ними.

Производительность и накладные расходы

Примитивные типы, как было описано выше, позволяют достичь высокой производительности из-за их прямой аллокации в стеке или регистрах. Тем не менее, их несогласованность с объектной системой может приводить к значительным накладным расходам [5]. Оптимизации работы с типами в JVM подробно рассмотрены в [6]

- **Операции упаковки и распаковки (Boxing/Unboxing):** Эти операции, интегрирующие примитивы в объектную иерархию, влекут за собой:
 - **Аллокацию памяти в куче:** Для каждого упакованного примитивного значения создается новый объект в куче, что увеличивает потребление памяти.
 - **Дополнительные циклы процессора:** Создание и инициализация объектов-оберток, а также последующее их удаление сборщиком мусора, требуют процессорного времени.
 - **Увеличение нагрузки на сборщик мусора:** Большое количество короткоживущих объектов-оберток создает дополнительную работу для сборщика мусора, потенциально приводя к задержкам в работе приложения.
- **Избыточные преобразования типов:** В сложных системах, где примитивы часто передаются между функциями, ожидающими объектные типы, и наоборот, могут возникать множественные операции упаковки и распаковки, что негативно сказывается на общей производительности системы.

Влияние на проектирование языка и его особенности

Асимметрия между примитивными и объектными типами оказывает глубокое влияние на архитектуру и проектирование самих управляемых языков, усложняя их реализацию и использование.

- **Сложность дизайна и реализации компилятора/рантайма:** Разработчикам языков приходится вводить специальные правила и исключения для обработки примитивных типов, которые не соответствуют общей объектной модели. Это увеличивает сложность компилятора и среды исполнения, требуя специализированных путей кода для различных типов.
- **Ограничения в расширяемости:** Механизмы расширения языка, такие как операторная перегрузка или метапрограммирование, могут быть ограничены или усложнены из-за необходимости учитывать различия между примитивами и объектами.
- **Влияние на ключевые функции языка:**
 - **Рефлексия:** Механизмы рефлексии (интроспекции и модификации кода во время выполнения) должны предоставлять отдельные интерфейсы для примитивных и объектных типов или вводить специальные обертки для работы с примитивами.
 - **Сериализация:** Унифицированная сериализация данных становится более сложной, поскольку необходимо обрабатывать как объекты, так и примитивные значения.
 - **Типы, допускающие значение null:** Введение безопасных nullable-типов (например, `int?` в C#) часто требует дополнительной работы для примитивов, в то время как объектные типы по умолчанию могут быть `null`.
- **Дополнительная нагрузка на разработчика:** Разработчики, использующие управляемые языки, вынуждены постоянно учитывать различия между примитивами и объектами и помнить, когда и где следует использовать примитив, а когда — его объектную обертку, добавляет сложности в процесс разработки.

2 Постановка задачи

2.1 Контекст

В данной работе речь пойдет о высокоуровневом языке программирования с управляемой средой исполнения, поддерживающей два языка программирования — статически типизированный язык, похожий в большей степени на TypeScript, и динамически типизированный, схожий с JavaScript.

Язык поддерживает императивные, объектно-ориентированные, функциональные и шаблонные паттерны программирования и комбинирует разные семантические аспекты TypeScript, Java и Kotlin. На данный момент язык находится в активной стадии разработки.

Примитивные типы в разрабатываемом языке обладают основными характеристиками, описанными ранее — они:

- не участвуют в подтипировании (в том числе с типом `Object`)
- не могут быть компонентами юнион-типов
- не могут приниматься в шаблонных в качестве аргумента
- не имеют методов и других свойств объектов

Для обеспечения указанной функциональности язык предоставляет объектные аналоги примитивных типов (далее - объектные аналоги примитивных типов, примитивоподобные объекты), представляющие собой объектную обертку с соответствующими методами и правилами наследования (например, `Int` — объектный аналог примитивного типа `int`). В случаях необходимости между примитивным типом и его аналогом происходит скрытая конверсия, что усложняет семантический анализ программ. Более того, синтаксически допускаются конструкции вида `int | undefined` или `Set<int>`, которые интерпретируются компилятором как `Int | undefined` и `Set<Int>`. Несоответствие свойств `int` и `Int` приводит к непредвиденному поведению в крайних случаях.

Далее в тексте `int` и `Int` будут использоваться в качестве основного примера.

Цель работы: улучшение семантического анализа программ посредством устранения концепции примитивных типов как отдельной категории и унификации системы типов.

2.2 Задачи исследования

Для достижения поставленной цели необходимо решить следующие задачи:

1. Провести детальный анализ текущего состояния семантического анализа с целью идентификации мест, где наличие примитивных типов приводит к:
 - усложнению логики анализа
 - неоднозначности интерпретации

- необходимости специальных правил обработки (скрытые конверсии, union-типы, generics)
- 2.** Разработать формальную спецификацию унифицированной системы типов, которая:
- исключает концепцию примитивных типов
 - интегрирует их функциональность в объектную модель
 - сохраняет производительность операций (арифметические, логические)
 - обеспечивает корректность семантики
- 3.** Спроектировать и реализовать модификации в подсистеме семантического анализа, обеспечивающие:
- проверку совместимости типов
 - разрешение перегрузок
 - вывод типов
 - работу с метаданными
- 4.** Разработать набор тестовых сценариев, охватывающих:
- шаблонные с числовыми аргументами
 - union-типы
 - операции с числовыми значениями
 - проблемные краевые случаи
- 5.** Оценить влияние решения на:
- сложность и точность семантического анализа
 - удобство разработки
 - потенциальную производительность
- с использованием формальных метрик:
- уменьшение количества специальных правил
 - сокращение ветвлений в коде анализатора
 - результаты тестовых сценариев

2.3 Требования к решению

2.3.1 Функциональные требования

- 1. Унификация системы типов:** Разработанное решение должно обеспечить:

- полную интеграцию всех типов (числовых, логических) в общую объектную иерархию
- участие базовых типов в механизмах подтипирования
- устранение разделения на примитивные и объектные типы

2. Поддержка продвинутых конструкций: Все типы должны корректно использоваться в:

- **Union-типах:** конструкции вида `number | undefined` или `boolean | null` должны быть валидными
- **Дженериках:** базовые типы как аргументы (`Set<number>`, `Map<string, boolean>`) без скрытых преобразований
- **Наследовании/Подтипировании:** соблюдение общих правил для базовых типов

3. Устранение скрытых конверсий: Необходимо исключить:

- автоматические механизмы упаковки (boxing)
- автоматическую распаковку (unboxing) значений
- неявные преобразования между разными представлениями типов

4. Семантическая корректность: Анализатор должен обеспечивать:

- точное выявление типовых ошибок
- однозначное разрешение типов в выражениях
- предсказуемое поведение программ

5. Сохранение синтаксиса: Требуется:

- сохранить существующий синтаксис (`int`, `number`, `boolean`)
- обеспечить соответствие внутренней интерпретации унифицированной модели

2.3.2 Нефункциональные требования

1. Производительность:

- отсутствие существенного замедления семантического анализа
- оптимизация алгоритмов проверки типов

2. Эффективность кода:

- отсутствие заметного снижения производительности исполняемого кода
- сравнимая эффективность с оригинальной реализацией

3. Качество кода анализатора:

- повышение читаемости и поддерживаемости
- модульная структура
- упрощение логики обработки типов

4. Удобство разработки:

- интуитивно понятная модель типов
- снижение когнитивной нагрузки
- минимизация неочевидных ошибок

2.4 Ожидаемые результаты

В результате выполнения дипломной работы ожидается получить:

- **Спецификацию унифицированной системы типов** для высокоуровневого управляемого языка, включающую:
 - формальное описание типовой системы
 - правила подтипирования
 - алгоритмы проверки типов
- **Модифицированную подсистему семантического анализа с:**
 - поддержкой унифицированных типов
 - устранением специальных случаев для примитивов
 - улучшенной архитектурой
- **Комплекс тестовых примеров**, покрывающих:
 - базовые операции с типами
 - union-типы и дженерики
 - краевые случаи
 - производительность анализа
- **Оценочные метрики** по:
 - сложности семантического анализа
 - эффективности работы компилятора
 - удобству использования языка

3 Обзор существующих решений

Интеграция примитивных типов в высокоуровневую систему типов и их влияние на семантический анализ

3.1 Явное разделение с автоматическим преобразованием

- **Суть:** Примитивные типы ('int', 'float', 'boolean') и объектные типы ('Integer', 'Float', 'Boolean') существуют параллельно и явно различимы в системе типов языка. Компилятор автоматически вставляет преобразования (боксинг - примитив -> объектная обертка, анбоксинг - объектная обертка -> примитив) там, где контекст требует типа другого вида (например, передача 'int' в метод, ожидающий 'Object', или использование 'Integer' в арифметической операции). Например, о гибридном подходе в CLR можно узнать из [7].
- **Влияние на систему типов:**
 - Явный дуализм типов
 - Примитивы не являются частью объектной иерархии
 - Необходимость учёта примитивных типов в правилах подтипирования
- **Влияние на семантический анализ: Значительно усложняет анализ**
 - Отслеживание контекстов, требующих преобразований
 - Разрешать перегрузки методов с примитивными и объектными параметрами (иногда приводя к неочевидному выбору)
 - Обращивать потенциальные `NullPointerException` при анбоксинге `null`
 - Учитывать различия в семантике (например, `==` для примитивов vs. для объектов)
 - Иметь отдельные ветви кода для проверки типов примитивов и объектов
- **Преимущества:** Позволяет использовать примитивы для производительности и объектные обертки там, где нужна полиморфность (коллекции). Понятна разработчикам низкого уровня.
- **Недостатки:** Сложная система типов и семантический анализ, риск ошибок `NullPointerException` из-за неявного анбоксинга, потенциальные накладные расходы на преобразования, концептуальный разрыв для разработчика. Также накладные расходы на `boxing/unboxing` в Java могут достигать 20% производительности (см. [5])
- **Примеры:** Java (классический пример), ранние версии C#

```
1 Integer x = 10;    // Автобоксинг
2 int y = x;         // Автоанбоксинг
3 if (y == x) {      // Сравнение с автоанбоксингом
4     System.out.println("Equal");
5 }
```

Пример в Java

3.2 Единая иерархия типов с значимыми типами

- **Суть:** Примитивные типы реализованы как **значимые типы (value types)**, которые являются частью единой объектной иерархии типов (например, наследуются от базового класса `ValueType`, который сам наследуется от `Object`). Все типы (и ссылочные, и значимые) формально являются подтипами `Object`. Однако, между ссылочными (классы) и значимыми (структуры, примитивы) типами сохраняется фундаментальное различие в семантике: передача по ссылке и передача по значению (копированию), размещение в куче и в стеке/встроено.
- **Влияние на систему типов:** Формально единая иерархия, но с глубоким внутренним разделением. Примитивы/значимые типы могут реализовывать интерфейсы. Возможно ограниченное наследование для значимых типов (или его отсутствие).
- **Влияние на семантический анализ: Усложнен.** Анализатор должен:
 - Различать ссылочные и значимые типы на протяжении всего анализа.
 - Учитывать семантику копирования при присваивании и передаче в методы для значимых типов.
 - Обращивать боксинг/анбоксинг (упаковку/распаковку) при необходимости преобразования значимого типа в ссылочный (`object`, интерфейс) и обратно, со всеми вытекающими последствиями (накладные расходы, `Null?`).
 - Учитывать различия в поведении операторов (например, `==` по умолчанию для значимых типов сравнивает значения, а для ссылочных - ссылки).
- **Преимущества:** Более единообразная модель типов, чем в Java. Значимые типы позволяют создавать эффективные пользовательские структуры данных. Возможность полиморфизма через интерфейсы.
- **Недостатки:** Сохраняется концептуальная сложность разделения `ref/value`. Семантический анализ все еще должен обрабатывать два разных вида типов и преобразования между ними. Риск неочевидных накладных расходов на упаковку.
- **Примеры:** C# (структуры `struct`, примитивы как псевдонимы для системных структур типа `System.Int32`), Swift (value semantics для структур и перечислений).

3.3 Примитивы как оптимизация компилятора

- **Суть:** Система типов языка оперирует только высокоуровневыми объектными типами. Примитивные типы абстрагированы на уровне семантики языка. Компилятор на поздних стадиях (после семантического анализа) агрессивно оптимизирует использование этих объектов:

- заменяет их на низкоуровневые примитивные значения,
- подставляет реализацию их методов напрямую в код,
- устраняет накладные расходы на вызовы методов и выделение памяти.

Примитив используется только как реализационная деталь оптимизации, невидимая для семантики языка.

- **Влияние на систему типов: Единая объектная модель.** Примитивы представлены как специальные неизменяемые объектные типы (часто `final` классы или `inline` классы). Для системы типов и разработчика они:

- выглядят и ведут себя как обычные объекты,
- имеют методы,
- могут быть упакованы в общие интерфейсы.

- **Влияние на семантический Анализ: Существенно упрощен.** Анализатор работает исключительно с объектными типами. Нет необходимости:

- Различать примитивы и объекты при проверке типов.
- Обращивать правила боксинга/анбоксинга (их нет на уровне семантики).
- Беспокоиться о `NullPointerException` для самих объектных аналогов примитивов.

- **Преимущества:**

- Максимально простая и единообразная система типов,
- Упрощенный семантический анализ для высокоуровневых конструкций,
- Сохранение производительности примитивов через оптимизацию,
- Высокая абстракция для разработчика.

- **Недостатки:**

- Сложность реализации оптимизирующего компилятора,
- Необходимость четких правил для компилятора (например, часто требуется `final`/неизм)
- Возможные ограничения:
 - * массивы примитивных объектов могут быть менее эффективны,

- * работа с рефлексией может показывать обертку.

– **Примеры:**

- Kotlin (**inline** классы для представления примитивоподобных типов, см. [8]),
- Scala (классы-значения **AnyVal** и их подклассы для **Int**, **Double** и т.д. - хотя в Scala есть и примитивы JVM, **AnyVal** абстрагирует их на уровне семантики Scala).

3.4 Полное удаление примитивных типов

– **Суть:**

- В системе типов языка отсутствует само понятие "примитивный тип"
- Все данные (целые числа, числа с плавающей точкой, булевы значения, символы) являются полноценными объектами
- Операции над ними реализованы исключительно как методы этих объектов
- Любая низкоуровневая оптимизация (представление в виде примитивных значений процессора или **inline**-подстановка операций) является исключительной задачей компилятора или среды выполнения:
 - * Происходит после этапа семантического анализа
 - * Не влияет на правила языка и работу семантического анализатора

– **Влияние на Систему Типов:**

- **Абсолютно единая объектная иерархия**
- Все типы являются объектными
- Нет дуализма или разделения на **ref/value** на уровне абстракции языка

– **Влияние на Семантический Анализ:**

- **Максимально упрощен и унифицирован**
- Анализатор:
 - * Работает только с объектными типами и их методами
 - * Проверяет типы и разрешает перегрузки методов по единым правилам
 - * Обрабатывает операции как обычные вызовы методов (**a.plus(b)**, **x.equals(y)**)
 - * Не содержит никакого кода, специфичного для обработки примитивов

– **Преимущества:**

- Наивысшая степень абстракции и согласованности
- Простота семантического анализа

- Концептуальная чистота
- Устранение целых классов ошибок, связанных с примитивами
- **Недостатки:**
 - Высокие требования к оптимизирующему компилятору/рантайму
 - Потенциальные сложности с низкоуровневым взаимодействием
 - Исторически возможная неестественность представления операций как методов
- **Примеры:**
 - Smalltalk (Опыт Smalltalk подтверждает, что полная унификация типов возможна, но требует сложного компилятора [9])
 - Ruby (и объекты, и числа имеют методы)

4 Исследование и построение решения задачи

4.1 Архитектурное решение

В работе реализована стратегия абстрагирования примитивных типов посредством их представления в виде объектов высокоуровневой системы типов, где примитивные операции (арифметика, сравнения) выполняются непосредственно над объектным аналогом примитивного типа. Физическое представление примитивов и низкоуровневые оптимизации генерируются компилятором после этапа семантического анализа, не влияя на корректность и согласованность правил типизации.

4.2 Обоснование выбора стратегии

На основании проведённого обзора существующих решений выбрана стратегия «Примитивы как оптимизация компилятора» по следующим причинам:

1. Упрощение семантического анализа

- Анализатор работает только с объектными типами (например, `Int` как класс-обёртка)
- Устранение дуализма типов (как в Java) и проблем упаковки (как в C#)

2. Совместимость с целями языка

- Чистая объектная модель критична для семантической согласованности высокоуровневого управляемого языка.

3. Практическая эффективность

- Оптимизации (анбоксинг, инлайнинг методов - подстановка тела непосредственно в место вызова) выполняются на последних этапах и не нарушают семантику проверки типов.

4.3 Описание решения

- Все примитивоподобные типы становятся экземплярами Object
- Замена на низкоуровневые примитивы выполняется только на этапе оптимизации компиляции
- Именование семантики массивов во время исполнения во избежание неэффективной работы с ними




Рис. 1: Этапы работы компилятора с выделением семантического анализа

Новая унифицированная система типов предусматривает:

1. Каждый примитивный тип полностью эквивалентен своей объектной обёртке, являющейся подклассом Object (включая специальные типы: void/Void, undefined/Undefined, null/Null)
 - Арифметические операции выполняются непосредственно над объектами без распаковки
 - Тип объектный примитивоподобный тип становится полноценным участником union-типов
 - Операторы == и === реализуют сравнение по значению (аналогично поведению для String)

4.4 Изменения в семантике языка

4.4.1 Эквивалентные сценарии

Для наглядности далее в тексте в качестве базового примера будут использоваться типы: int (примитивный) → Int (объектный аналог)

Примитивы	Объектные аналоги
<code>let x = 1.0</code>	<code>let XX = new Number(1.0)</code>
<code>x++</code>	<code>XX++ [XX = new Number(XX.value + 1), неявный боксинг]</code>
<code>x == 0</code>	<code>XX == 0 [XX.unboxed() == 0, неявный анбоксинг]</code>
<code>x === 0</code>	<code>XX === 0</code>
<code>function f(XX: Number) {}; f(x)</code> [неявный боксинг]	<code>function f(x: number) {}; f(XX) [неявный анбоксинг]</code>
<code>function g<T>(t: T) {}; g(x) [неявный боксинг]</code>	<code>function g<T>(t: T) {}; g(XX)</code>
<code>let u: number null = 0 [неявная замена на Number]</code>	<code>let UU: Number null = 0</code>
<code>g<number>(0) [неявная замена на Number]</code>	<code>g<Number>(0)</code>
<code>typeof(x) == "number"</code>	<code>typeof(XX) == "Number"</code>

Рис. 2: Выделены места, где ранее выполнялись неявные преобразования

4.4.2 Новые допустимые конструкции

```
1 xx.toString() // ошибка компиляции до изменений, будет работать после
2 xx instanceof Object // ошибка компиляции до изменений, будет работать после
```

4.5 План реализации

1. **Модификация системы типов:** Убрать примитивные типы на этапе проверки корректности типов в арифметических операциях и преобразованиях типов
2. **Обработка констант:** Изменить представление литералов на этапе свёртки констант на объектные типы
3. **Оптимизация перед кодогенерацией:** Имплементировать модуль-оптимизацию, где объектные типы будут по возможности заменяться примитивными

5 Описание практической части

Компилятор рассматриваемого языка в основном написан на языке программирования C++.

Для наглядности далее в тексте в качестве базового примера будут использоваться типы: `int` (примитивный) \rightarrow `Int` (объектный аналог)

5.1 Арифметические операции

На данном этапе работы было необходимо модифицировать проверку корректности типов в арифметических операциях:

```
+ , - , += , -=  
  
++ , -  
  
* , / , % , *= , /= , %=  
  
<< , >> , <<= , >>= , >>> , >>>=  
  
| , |= , & , &= , ^ , ^= , || , &&  
  
< , <= , > , >= , == , === , !
```

В существующей реализации почти в каждой функции проверки производилось безусловное приведение типов операторов к примитивным, поэтому первым этапом работы было удаление или изменение кода, который приводил бы к замене объектных типов на их примитивные аналоги. Далее, основная функция, которая была нужна почти для всех вышеперечисленных операций (исключая логические и унарные) - функция, вычисляющая тип результата бинарного выражения. Ее поведение основывается на иерархии численных типов, оговоренной в спецификации. Следующий этап заключался в очистке кода от попыток свернуть константы в функциях проверки, чтобы вынести все константные вычисления в отдельный модуль.

5.2 Преобразования типов

Для реализации проверки легальности преобразования объектных примитивоподобных типов можно было переиспользовать алгоритм, использовавшийся для проверки преобразований примитивных типов, добавив дополнительные проверки на отношения объектов (`Union` и `Enum`). Структура функции для проверки корректности преобразования представлена на ??

5.2.1 Основные функции

Вычисление ранга типа

```
1  /**  
2  * Проверяет допустимость преобразования между упакованными примитивными типами.
```

```
3  * Основная идея: проверяет, можно ли безопасно преобразовать один упакованный
   тип
4  * в другой, переиспользуя алгоритмы проверки преобразований для примитивных
   типов.
5  */
6  bool IsLegalBoxedPrimitiveConversion(Type *target, Type *source) {
7      Checker *checker = this->GetChecker()->AsChecker();
8
9      // Проверка на null
10     if (target == nullptr || source == nullptr) {
11         return false;
12     }
13
14     // Обработка union типов- особый( случай)
15     if (target->IsUnionType() && source->IsObjectType()) {
16         // Получаем базовый примитивный тип для исходного типа
17         Type *sourceUnboxed = checker->MaybeUnboxType(source);
18         if (!sourceUnboxed || !sourceUnboxed->IsPrimitiveType()) {
19             return false;
20         }
21
22         // Ищем упакованный тип в union, который можно распаковать
23         Type *boxedUnionTarget =
24         target->AsUnionType()->FindUnboxableType();
25         if (!boxedUnionTarget) {
26             return false;
27         }
28
29         // Проверяем совместимость базовых примитивных типов
30         Type *targetUnboxed =
31         checker->MaybeUnboxType(boxedUnionTarget);
32         return targetUnboxed && targetUnboxed->IsPrimitiveType() &&
33             this->IsAssignableTo(sourceUnboxed, target);
34     }
35
36     // Оба типа должны быть объектными
37     if (!target->IsObjectType() || !source->IsObjectType()) {
38         return false;
39     }
40
41     // Хотя бы один тип должен быть упакованным примитивом
42     if (!target->AsObjectType()->IsBoxedPrimitive() &&
43         !source->AsObjectType()->IsBoxedPrimitive()) {
```

```
42     return false;
43 }
44
45 // Получаем базовые примитивные типы
46 Type *targetUnboxed = checker->MaybeUnboxType(target);
47 Type *sourceUnboxed = checker->MaybeUnboxType(source);
48
49 // Особый случай для int-перечислений-
50 if (source->IsIntEnumType()) {
51     targetUnboxed = checker->GlobalIntType();
52 }
53
54 // Проверяем что оба имеют примитивные базовые типы
55 if (!targetUnboxed || !sourceUnboxed ||
56     !targetUnboxed->IsPrimitiveType() ||
57     !sourceUnboxed->IsPrimitiveType()) {
58     return false;
59 }
60
61 // Проверяем совместимость примитивных типов
62 return this->IsAssignableTo(sourceUnboxed, targetUnboxed);
63 }
```

Листинг 1: GetTypeRank

5.3 Свёртка констант

Один из основных этапов работы - это имплементация модуля компиляции для сверки констант в начало стадии семантического анализа. Свёртка констант - вычисление константных выражений с последующей заменой выражений на результаты, выполняемое на отдельной стадии компиляции. Это оптимизация, которая:

- Ускоряет выполнение программы (избегает вычислений в runtime)
- Уменьшает размер генерируемого кода
- Позволяет обнаружить ошибки на этапе компиляции

Исплементированный модуль позволяет рекурсивно обойти `const` и `readonly` декларации и заменить константные выражения результатом их вычисления. Алгоритм свёртки констант реализован по аналогии с классическими методами [10]

5.3.1 Основной алгоритм

- Обход **AST** - рекурсивных обход синтаксического дерева программы

- **Идентификация константных выражений** - проверка, можно ли вычислить выражение на этапе компиляции (является ли выражение константным)
- **Вычисление констант** - выполнение операций над константами
- **Замена выражений** - подстановка вычисленных значений вместо исходных выражений

5.3.2 Поддерживаемые типы и операции

Типы данных

- Числовые литералы (int, float, double)
- Символьные литералы (char)
- Булевы значения (true/false)
- Строковые литералы
- Enum значения

Операции

- Арифметические +, -, *, /, %
- Битовые &, |, ^, ~, <<, >>, >>>
- Логические &&, ||, !
- Сравнения ==, !=, <, >, <=, >=
- Унарные +, -, ~

5.3.3 Детали реализации

Типизация и преобразование типов

- Используется система рангов типов TypeRank для определения приоритета преобразований
- Реализованы безопасные преобразования между типами с проверкой диапазонов ([11] - Безопасные преобразования типов при свёртке констант требуют проверки диапазонов)
- Обработка деления на ноль

```
1 enum class TypeRank {
2     INT8,
3     INT16,
4     INT32,
5     INT64,
6     FLOAT,
7     DOUBLE,
8     CHAR
9 };
```

Листинг 2: Перечисление рангов типов

5.3.4 Основные функции

Вычисление ранга типа

```
1 static TypeRank GetTypeRank(const ir::Literal* lit) {
2     if (lit->IsCharLiteral()) {
3         return TypeRank::CHAR;
4     }
5
6     auto num = lit->AsNumberLiteral()->Number();
7     if (num.IsByte()) return TypeRank::INT8;
8     if (num.IsShort()) return TypeRank::INT16;
9     if (num.IsInt()) return TypeRank::INT32;
10    if (num.IsLong()) return TypeRank::INT64;
11    if (num.IsFloat()) return TypeRank::FLOAT;
12    if (num.IsDouble()) return TypeRank::DOUBLE;
13 }
```

Листинг 3: GetTypeRank

Получение значения литерала

```
1 template <typename TargetType>
2 static TargetType GetVal(const ir::Literal* node) {
3     // Обработка булевых литералов
4     if constexpr (std::is_same_v<TargetType, bool>) {
5         return node->AsBooleanLiteral()->Value();
6     }
7
8     // Обработка символьных литералов
9     if constexpr (std::is_same_v<TargetType, char16_t>) {
10        return node->AsCharLiteral()->Char();
11    }
12 }
```

```
13     auto numNode = node->AsNumberLiteral();
14
15     // Обработка числовых литералов разных типов
16     if constexpr (std::is_same_v<TargetType, int8_t>) {
17         return numNode->Number().GetByte();
18     }
19     if constexpr (std::is_same_v<TargetType, int16_t>) {
20         return numNode->Number().GetShort();
21     }
22     // ...
23     if constexpr (std::is_same_v<TargetType, double>) {
24         return numNode->Number().GetDouble();
25     }
26 }
```

Листинг 4: GetVal

Преобразование значений между типами

```
1 template <typename To>
2 static To CastValTo(const ir::Literal* lit) {
3     // Обработка булевых литералов
4     if (lit->IsBooleanLiteral()) {
5         return static_cast<To>(GetVal<bool>(lit));
6     }
7
8     // Определение ранга типа и преобразование
9     auto rank = GetTypeRank(lit);
10    switch (rank) {
11        case TypeRank::DOUBLE:
12            return static_cast<To>(GetVal<double>(lit));
13        case TypeRank::FLOAT:
14            return static_cast<To>(GetVal<float>(lit));
15        // ...
16        case TypeRank::CHAR:
17            return static_cast<To>(GetVal<char16_t>(lit));
18    }
19 }
```

Листинг 5: CastValTo

Обработка ошибок

- Генерация диагностических сообщений для недопустимых операций
- Реализованы безопасные преобразования между типами с проверкой диапазонов

- Отдельные функции преобразований между целыми и вещественными типами

Оптимизации

- Использование битовых операций для безопасной работы с целыми числами
- Специальная обработка строковых конкатенаций
- Оптимизация шаблонных литералов

5.4 Оптимизация

Реализованная оптимизация представляет собой систему преобразования типов, которая рекурсивно анализирует и модифицирует абстрактное синтаксическое дерево (AST) для выполнения операций `nboxing` (распаковки) и `boxing` (упаковки) типов.

Архитектура оптимизации

5.4.1 Класс `UnboxVisitor`

Рекурсивный анализ дерева проводится с помощью специального класса `UnboxVisitor`, реализующего методы `VisitX` для различных типов узлов AST. Его задачи:

1. Обойти AST и найти места, где можно заменить `boxed`-типы на примитивы
2. Вставить явные преобразования (например, вызовы `unboxed()`, `valueOf()`, `intrinsic-функции`)
3. Обновить соответствующие типы в выражениях, объявлениях и сигнатурах
4. Заново запустить функцию валидации ноды

Подобный подход к преобразованию типов используется в TypeScript [12]

5.4.2 Обрабатываемые узлы AST

Примеры обрабатываемых узлов:

- `VisitCallExpression` — вызовы функций
- `VisitBinaryExpression` — бинарные операции (`+`, `==`, `&&` и т. д.)
- `VisitMemberExpression` — доступ к полям/методам (`obj.field`, `arr[index]`)
- `VisitReturnStatement` — возвращаемые значения
- `VisitVariableDeclarator` — объявления переменных

5.4.3 Механизм работы `Visitor`'ов

Каждый узел AST имеет метод `Accept(visitor)`. При вызове `astNode->Accept(visitor)` управление передаётся в соответствующий метод `VisitX` у `UnboxVisitor`.

5.4.4 Пример обработки CallExpression

```
1 void VisitCallExpression(ir::CallExpression *call) override {
2     // 1. Обновление типов аргументов
3     for (size_t i = 0; i < call->Arguments().size(); i++) {
4         auto *arg = call->Arguments()[i];
5         auto *expectedType =
6         call->Signature()->Params()[i]->TsType();
7         call->Arguments()[i] = AdjustType(uctx_, arg, expectedType);
8     }
9
10    // 2. Обновление возвращаемого типа
11    if (call->Signature()->ReturnType()->IsPrimitiveType()) {
12        call->SetTsType(call->Signature()->ReturnType());
13    }
```

Листинг 6: Обработка вызовов функций

5.4.5 Логика преобразования типов

Решение о том, нужно ли вставлять boxing, unboxing или конверсию примитивов, принимается с помощью метода AdjustType:

```
1 static ir::Expression *AdjustType(UnboxContext *uctx,
2                                   ir::Expression *expr,
3                                   checker::Type *expectedType) {
4     // Если выражение - примитив, а ожидается объект → boxing
5     if (expr->TsType()->IsPrimitiveType()
6         && expectedType->IsObjectType()) {
7         return InsertBoxing(uctx, expr);
8     }
9     // Если выражение - boxed объект-, а нужен примитив → unboxing
10    if (TypeIsBoxedPrimitive(expr->TsType())
11        && expectedType->IsPrimitiveType()) {
12        return InsertUnboxing(uctx, expr);
13    }
14    // Если оба примитива, но разных типов → конверсия
15    if (expr->TsType()->IsPrimitiveType()
16        && expectedType->IsPrimitiveType()) {
17        return InsertPrimitiveConversion(uctx, expr, expectedType);
18    }
19    return expr;
20 }
```

Листинг 7: Метод AdjustType

5.4.6 Пример преобразования

Исходный код

```
1 let x: Int = 10;  // Int - объектный тип
2 let y: int = x + 5;  // int - примитив
```

Преобразование AST

```
1 BinaryExpression(
2   left: Identifier("x", type=Int),
3   op: +,
4   right: NumberLiteral(5, type=int)
5 )
```

Листинг 8: AST до оптимизации

```
1   BinaryExpression(
2     left: CallExpression(
3       callee: MemberExpression(
4         object: Identifier("x", type=Int),
5         property: "unboxed"
6       ),
7       type=int
8     ),
9     op: +,
10    right: NumberLiteral(5, type=int)
11  )
```

Листинг 9: AST после оптимизации

6 Заключение

бебебебе ляляляляля

Список литературы

1. *Pierce B. C.* Types and Programming Languages. — Cambridge, MA : MIT Press, 2002.
2. *Wright A. K., Felleisen M.* A Syntactic Approach to Type Soundness // Information and Computation. — 1994. — Т. 115, № 1. — С. 38–94. — DOI: 10.1006/inco.1994.1093.
3. *Oracle.* The Java Language Specification. — 2023. — URL: <https://docs.oracle.com/javase/specs/> (дата обр. 15.11.2023).
4. *International E.* ECMA-334: C# Language Specification. — 2022. — URL: <https://www.ecma-international.org/publications-and-standards/standards/ecma-334/> (дата обр. 15.11.2023).
5. *Chen L.* The Hidden Costs of Boxing in Java and C# // Journal of Systems Programming. — 2019. — Т. 102. — С. 30–42.
6. *Goetz B., Peierls T., Bloch J.* Java Concurrency in Practice. — Addison-Wesley, 2006. — Содержит разделы о работе JVM с примитивами.
7. *Richter J.* CLR via C#. — Microsoft Press, 2012. — Детали реализации CLR, включая boxing/unboxing.
8. *JetBrains.* Kotlin Language Documentation. — 2023. — URL: <https://kotlinlang.org/docs/home.html> (дата обр. 15.11.2023).
9. *Smith J.* Eliminating Primitive Types in Managed Languages // ACM SIGPLAN Notices. — 2020. — Т. 55, № 1. — С. 1–15.
10. *Compilers: Principles, Techniques, and Tools / A. V. Aho [и др.].* — 2-е изд. — Pearson Education, 2007.
11. *Красовский В.* Алгоритмы статического анализа для оптимизации компиляторов // Программирование. — 2022. — № 3. — С. 45–60.
12. *Microsoft.* TypeScript Handbook. — 2023. — URL: <https://www.typescriptlang.org/docs/handbook/> (дата обр. 15.11.2023).
13. *Современные подходы к реализации языков программирования / под ред. А. Горбенко.* — СПб : Питер, 2018.
14. *Иванов А.* Унификация типов в языках с динамической и статической типизацией // Труды ИСП РАН. — 2021. — Т. 33. — С. 45–60.
15. *Odersky M.* Type System Unification in Scala 3 // Proceedings of the OOPSLA Conference. — 2021. — С. 1–20.
16. *Research M.* Type System Unification in .NET 7 : тех. отч. / Microsoft. — 2022.